

암보험 상담 챗봇을 위한 LLM 기반 고객 질의 유형 분류 파이프라인

정효정

University of California, Los Angeles,

ahjjung@ucla.edu

Abstract

최근 거대 언어 모델(Large Language Model, LLM)의 발전으로 챗봇은 일반적인 대화를 넘어 전문 분야 상담 도구로도 활용되고 있다. 그러나, 보험과 같이 주의 사항이 많고 정보의 정확성이 중요한 분야에서는 사용자의 질문 유형을 적절하게 파악하여 정보를 제공하는 것이 중요하다. 본 연구는 암보험 상담 챗봇을 대상으로 고객 질의 유형을 분류하기 위한 LLM 기반 유형 분류 파이프라인(Figure 1)을 제안한다. 유형(카테고리)이 정의되지 않은 상황을 가정하여, 암보험 상품요약서와 의료 대화 데이터셋을 활용하여 K-Means Clustering을 통해 군집을 도출하였다. 해당 군집을 바탕으로 카테고리를 정의하고, 해당 카테고리명과 LLM을 이용하여 합성 데이터셋(testset)을 생성하였다. 이후, zero-shot prompting 방식의 LLM 기반 유형 분류기를 구축하였다. 실험 결과, 표현 패턴이 명확한 카테고리는 상대적으로 높은 분류 성능을 보였으며, 의미상으로 중첩되는 카테고리는 성능 저하가 관찰되었다. 본 연구는 명확한 라벨과 데이터셋이 존재하지 않는 상황에서도, LLM을 활용하여 카테고리를 정의하고, 분류기를 구축할 수 있는 실용적인 접근 방식을 제시한다.¹

1 Introduction

현재 인공지능의 폭발적인 성장은 우리 사회에 다양한 이점을 가져다주고 있다. 특히 텍스트를 기반으로 훈련된 거대 언어 모델의 경우, 챗봇의 형태로 사용자에게 배포되어 일상적인 대화를 넘어서 특정 분야에 대한 상담, 공부 등 사용자가 물어보는 것에 대해 답을 해주며 상호작용을 하고 있다. 거대 언어 모델 기반 챗봇은 이점과 편리함을 제공하고 있지만, 아직 한계점이 존재한다. 먼저, 사용자가 원하는 방향으로 답변을 해준다거나 근거가 확실하지 않은 답변을 하는 환각

¹본 연구 구현 및 실험 코드: https://github.com/alicehjjung/insurance_chatbot_classification_pipeline.git




Figure 1: 암보험 상담 챗봇을 위한 LLM 기반 고객 질의 유형 분류 파이프라인

(Hallucination)의 문제점이 있다. 이 환각 문제는 의료 분야에서는 각별하게 조심해야 하는 문제이다. 또한, 보험처럼 주의 사항이 많은 내용이면 인공지능이 잘못된 정보를 전달했을 때, 사용자에게 부작용 발생할 수 있다. 따라서 암보험을 가입하려는 고객을 상담하는 챗봇에서는, 사용자의 질문 유형을 정확히 파악하여 해당 유형에 맞는 정보를 제공하는 것이 중요하다.

본 연구는 암보험 상담 챗봇을 대상으로 고객 질의 유형을 분류하기 위한 LLM 기반 유형 분류 파이프라인을 제시한다. 보험 챗봇과 관련된 데이터셋이 존재하지 않는 상황을 가정하여, 기존 보험 상품 요약서와 외부 챗봇 데이터셋을 활용하여 의미 있는 군집을 도출하고, 이를 기반으로 고객 질의 유형 카테고리를 정의한다. 이후, LLM을 이용한 평가용 데이터셋을 생성하고, zero-shot prompting 방식의 LLM 기반 유형 분류기를 구축하여 평가한다. 본 연구는 크게 두 단계로 구성된다. 첫째, 암보험을 가입하려는 고객이 문의할 수 있는 질의 유형을 카테고리화 하고, 둘째, 정의된 카테고리를 기반으로 LLM을 활용한 유형 분류기를 구축 및 분석한다.

2 Text Clustering via Unsupervised Learning

알고리즘 선택 암보험 가입을 고려하는 고객이 문의할 수 있는 질문 유형에 대한 사전 정의된 데이터셋이

나 라벨이 존재하지 않기 때문에, 본 연구에서는 비지도 학습(unsupervised learning) 접근 방식을 채택하였다. 비지도 학습을 통해 데이터 내에 잠재된 문장 유형을 탐색한 후, 각 유형에 대해 사람이 직접 의미를 해석하고 카테고리를 정의하는 방식을 선택하였다.

비지도 학습 알고리즘 중에서는 K-means clustering을 사용하였다. 본 문제는 문장 간의 의미적 유사성을 기반으로 질문을 묶는 것이 목적이므로, 임베딩 공간에서의 거리 정보를 활용하는 거리 기반 군집화 방법이 적합하다고 판단하였다. 또한 K-means는 구조가 단순하고 해석 가능성이 높아, 이후 각 군집에 의미적 라벨을 부여하는 과정에 적합하다고 생각되어 선택하였다.

2.1 암보험 관련 대화 데이터 카테고리화

2.1.1 데이터 소개

암보험 관련 대화 유형을 카테고리화하기 위한 데이터셋으로는 한화생명 e암보험(비갱신형) 무배당 상품 요약서 (HanwhaLife, 2025) PDF 파일을 사용하였다. 해당 문서는 보험 공식 약관 및 설명 자료로, 고객이 암보험과 관련하여 문의할 수 있는 다양한 주제를 포괄하고 있다.

2.1.2 데이터 전처리

PDF 문서를 군집화에 적합한 텍스트 데이터로 변환하기 위해, unstructured 라이브러리를 사용하여 문서를 전처리하였다. 이 과정에서 제목(title)을 기준으로 텍스트를 나누었으며, 각 텍스트 청크의 최대 길이는 1200자로 제한하였다.

또한 군집화 결과가 문서 형식이나 불필요한 표기법에 따라 영향받지 않도록, 페이지 번호, 조항/관/항/호 표기, 회사명, 문서명, 불필요한 기호 및 문장부호 등 의미와 무관한 요소들을 제거하였다.

숫자 정보의 경우, 액수나 기간이 문장 의미보다는 값 자체의 차이로 군집화되는 것을 방지하기 위해, 금액은 [AMOUNT], 시간 관련 표현은 [YEAR], [MONTH], [DAY] 등의 토큰으로 치환하였다.

2.1.3 실루엣 계수를 이용한 군집 개수(k) 선택

적절한 군집 개수(k)를 결정하기 위해 실루엣 계수(silhouette score)를 사용하였다.

k 값 후보로는 8, 10, 12, 15, 18 을 설정하여 실험을 진행하였으며, 그 결과 k=15일 때 가장 높은 실루엣 계수를 보였다. 이에 따라 최종적으로 K-means clustering에서 군집 개수를 15로 설정하였다. (Figure 2)

2.1.4 K-means Clustering

전처리된 텍스트 데이터는 Vertex AI의 text-multilingual-embedding-002 모델을 사용하여

Table 1: 암보험 카테고리

Cluster ID	Category Description
Cluster 0	암보험금 청구 및 지급 절차
Cluster 1	암 진단 후 납입면제 및 계약 유지
Cluster 2	장기요양 및 복지
Cluster 3	연금·세제
Cluster 4	암보험 해지·환급 및 계약대출
Cluster 5	장해 보상 기준
Cluster 6	의료 행위
Cluster 7	암 진단 기준 및 적용 요건
Cluster 8	질병 분류
Cluster 9	의료기관 및 의료법
Cluster 10	계약자/전문계약자 정의
Cluster 11	개인정보·민감정보
Cluster 12	공적보험
Cluster 13	형사처벌·일반 법률 규정
Cluster 14	자동차·운송수단 정의

임베딩 벡터로 변환하였다. 생성된 임베딩 벡터를 기반으로, scikit-learn의 K-means 알고리즘을 적용하여 총 15개의 군집으로 텍스트를 군집화하였다.

2.1.5 카테고리화

군집화 이후, 각 클러스터의 중심 벡터와 유사한 상위 5개 문장을 대표 샘플로 추출하였다. 해당 대표 샘플들을 직접 검토하여, 각 군집이 의미하는 주제를 해석하고 적절한 카테고리 라벨을 부여하였다. 최종적으로 정의된 카테고리는 Table 1에 정리하였다.

2.2 일반 대화 관련 데이터 카테고리화

2.2.1 데이터 소개

암보험 상담 챗봇을 이용하는 고객은 암보험과 직접적으로 관련된 질문뿐만 아니라, 인사, 단순 질문, 추가 요청 등 일반적인 대화 문장을 함께 입력하는 경우가 많다. 또한 이러한 일반 대화 문장 중 일부는 질병이나 건강 상태와 간접적으로 연결될 수 있기 때문에, 본 연구에서는 의료 도메인과 관련된 대화 데이터셋을 활용하여 일반 대화 유형을 카테고리화하고자 하였다.

이를 위해 의료 특화 한국어 대화형 언어모델 ko-medical-chat의 학습 데이터셋인 squarelike/ko_medical_chat (Squarelike, 2023)을 사용하였다. 해당 데이터셋은 MedText와 ChatDoctor 데이터셋을 기반으로 GPT-3.5를 활용하여 한국어 의사-환자 대화 형태로 변환된 데이터로, 각 데이터는 실제 상담 상황처럼 대화(conversation) 단위로 구성되어 있다.

2.2.2 데이터 전처리

해당 데이터셋은 하나의 샘플에 의사와 환자의 여러 발화가 포함된 대화 형태이므로, 문장 단위의 군집화를 수행하기 위해 각 발화를 분리하여 개별 문장으로 저장하였다. 이를 통해 하나의 대화 안에 포함된 서로 다른 의도나 발화 유형이 군집화 과정에서 혼합되는 것을 방지하였다.

Table 2: 일반 대화 카테고리

Cluster ID	Category Description
Cluster 0	대처 방법 요청
Cluster 1	증상 파악
Cluster 2	상세 증상 설명
Cluster 3	검사 및 추가 진료 안내
Cluster 4	마무리 / 인사 / 감사 인사
Cluster 5	인사 / 대화 시작
Cluster 6	증상 지속 기간
Cluster 7	생활 습관 조언
Cluster 8	처방
Cluster 9	원인 추정 및 치료 계획
Cluster 10	정신 건강 치료 조언
Cluster 11	통증 치료 권고

본 데이터셋은 이미 정제된 형태로 제공되기 때문에, 추가적인 텍스트 정제 과정은 수행하지 않았다.

2.2.3 실루엣 계수를 이용한 군집 개수(k) 선택

일반 대화 데이터에 대해 적절한 군집 개수(k)를 결정하기 위해 실루엣 계수를 활용하였다.

k 값 후보로는 8, 10, 12, 15, 18을 설정하여 실험을 수행하였으며, 그 결과 k=12일 때 가장 높은 실루엣 계수를 나타냈다. 이에 따라 이후 K-means clustering 과정에서는 군집 개수를 12로 설정하였다. (Figure 3)

2.2.4 K-means Clustering

전처리된 일반 대화 문장 데이터는 Vertex AI의 text-multilingual-embedding-002 모델을 사용하여 임베딩 벡터로 변환하였다. 생성된 임베딩 벡터를 기반으로, scikit-learn의 K-means 알고리즘을 적용하여 총 12개의 군집으로 텍스트를 군집화하였다.

2.2.5 카테고리화

군집화 이후, 각 클러스터의 중심 벡터와 유사한 상위 5개 문장을 대표 샘플로 추출하였다. 해당 대표 샘플들을 직접 검토하여, 각 군집이 의미하는 주제를 해석하고 적절한 카테고리 라벨을 부여하였다. 최종적으로 정의된 카테고리는 Table 2에 정리하였다.

3 LLM-based Topic Classification

3.1 Synthetic Data Generation

3.1.1 카테고리 선택

앞선 군집화 결과를 바탕으로, 실제 암보험 상담 챗봇에서 고객이 직접 질문할 가능성이 높은 카테고리만을 선별하여 분류 실험에 활용하였다. 먼저 암보험 관련 카테고리 15개 중, 고객 문의와 직접적으로 연관성이 높은 다음의 4개 군집(Cluster 0, 1, 4, 7)을 선택하였다. 이후 챗봇 분류 태스크에 더 적합하도록 라벨명을 일부 수정하였다. (LABELS1)

다음으로 일반 대화 카테고리 12개 중, 실제 상담 상황에서 자주 등장할 수 있는 군집(Cluster 0, 3, 4, 5, 9,

Table 3: 유형 분류기를 위해 선택한 최종 카테고리

Label Set	Category Description
LABELS1	암 보험금 청구 및 지급 절차, 보험료 납입 면제 및 계약 유지, 암 보험 해지 및 환급, 암 보험 보장 범위 및 지급 사유
LABELS2	질문 및 요청, 다음 단계 안내, 마무리 및 감사 인사, 인사 및 대화 시작, 확인, 추가 상담 및 조언
LABELS3	보험 종류 소개, 고객 정보, 보험료

10)을 선택하였다. 해당 군집들 역시 챗봇 대화 흐름에 보다 적합하도록 라벨 명을 조정하였다. (LABELS2)

또한 군집화 과정에서는 명확히 나타나지 않았으나, 실제 암보험 상담 챗봇 운영 시 필요하다고 판단되는 카테고리를 추가로 정의하였다. (LABELS3)

암보험 관련 유형 분류에 사용한 최종 카테고리는 Table 3에 정리하였다.

3.1.2 데이터 생성

분류 성능 평가를 위한 Test Dataset은 Gemini-2.5-Pro 모델을 활용하여 합성 데이터(synthetic data) 형태로 생성하였다.

LABELS1과 LABELS2에 대해서는 기존 군집화 데이터셋이 존재하므로, 카테고리별로 문장 10개를 무작위로 추출해 few-shot prompting의 예시로 활용하였다. 사용한 프롬프트는 Appendix A.1.1에서 확인할 수 있다.

반면 LABELS3의 경우, 기존 데이터셋이 존재하지 않기 때문에 예시를 제공하지 않는 zero-shot prompting 방식을 사용하여 데이터를 생성하였다. 사용한 프롬프트는 Appendix A.1.2에서 확인할 수 있다.

3.1.3 데이터셋 요약

최종적으로 정의된 분류 카테고리는 총 13개이며, 카테고리별로 10개의 테스트 문장을 생성하여 총 130개의 문장으로 구성된 Test Dataset을 구축하였다.

3.2 실험 방법

본 연구에서는 거대언어모델(Large Language Model, LLM)을 활용하여 문장 유형을 분류하는 유형 분류기를 구축하였다. 분류 모델로는 Gemini-2.5-Pro를 사용하였으며, 각 입력 문장에 대해 사전에 정의된 13개의 카테고리 중 하나를 예측하도록 설정하였다. 분류 과정에서는 각 카테고리에 대한 예시를 제공하지 않는 zero-shot prompting 방식을 사용하였다. 이는 실제 챗봇 환경에서 사전 예시가 존재하지 않는 새로운 입력 문장에 대한 분류 가능성을 평가하기 위해서이다. 모델이 입력 문장과 카테고리 목록만을 기반으로 가장 적절한 유형을 예측하도록 설정하였다. 사용한 프롬프트는 Appendix A.2에서 확인할 수 있다.

Table 4: 전체 분류 성능

Metric	Precision	Recall	F1-score	N
Accuracy	—	—	0.48	130
Macro Average	0.27	0.21	0.22	130
Weighted Average	0.60	0.48	0.50	130

LLM의 출력 결과에는 간혹 특수문자나 영어 표현이 함께 포함되는 경우가 있어, 최종 예측 결과의 일관성을 확보하기 위해 정규표현식 기반의 후처리 과정을 적용하였다. 이를 통해 출력 결과에서 불필요한 특수문자 및 영어 표현을 제거하고, 정의된 카테고리 라벨만을 추출하였다.

3.3 실험 결과 및 분석

LLM 기반 유형 분류기의 성능 평가는 총 13개의 카테고리와 130개의 테스트 문장을 대상으로 수행하였다. 전체 accuracy는 0.48로 나타났으며, macro-average와 weighted-average F1 score는 각각 0.22와 0.50으로 측정되었다. (Table 4) 그러나 일부 카테고리가 테스트 셋에 포함되지 않은 상태에서 classification report가 생성되었기 때문에, 전체 분류 성능을 대표하는 지표로 사용하기에 한계가 있다. 이에 따라 본 연구에서는 accuracy를 주요 성능 지표로 사용하지 않고, 클래스별 F1 score를 중심으로 성능을 분석하였다. (Table 5)

마무리 및 감사 인사, 보험료, 암 보험 해지 및 환급 카테고리는 모두 0.8 이상의 높은 F1 score를 보였다. 이는 해당 카테고리들이 ‘감사합니다’, ‘보험료’, ‘환급’, ‘해지’와 같이 명확한 어휘적 단서를 포함하고 있으며, 비교적 고정된 표현 패턴을 갖기 때문으로 해석된다. 이러한 특성으로 인해 해당 카테고리들은 LLM 기반 분류기에서 상대적으로 안정적으로 분류되는 경향을 보였다.

반면 고객 정보, 다음 단계 안내, 보험 종류 소개, 보험료 납입 면제 및 계약 유지, 암 보험 보장 범위 및 지급 사유, 암 보험금 청구 및 지급 절차, 인사 및 대화 시작 카테고리는 0.4에서 0.6 사이의 중간 수준의 F1 score를 보였다. 이들 카테고리는 의미적으로는 구분되지만, 보험 도메인 내에서 유사한 표현을 공유하는 경우가 많아 분류 과정에서 혼동이 발생한 것으로 보인다. 예를 들어, 보험 종류 소개 카테고리에 속하는 문장인 “요즘 많이 이야기하는 표적항암치료나 면역항암치료 같은 신규 치료법을 보장하는 암보험도 있는지 궁금합니다”라는 ‘보장’이라는 단어가 포함되어 있다는 이유로 암 보험 보장 범위 및 지급 사유 카테고리로 분류되었다. 이는 보험 관련 질문 간 의미적 경계가 명확하지 않으면 발생하는 대표적인 오분류 사례로 볼 수 있다.

질문 및 요청, 추가 상담 및 조언 카테고리는 0.4 이하의 F1 score를 보였으며, 확인 카테고리는 F1 score

가 0.00으로 측정되었다. 이러한 카테고리들은 특정 키워드보다는 대화 맥락이나 화자의 의도에 기반하여 분류되어야 하는 특성이 있어, 다른 카테고리와의 미상으로 중첩되는 경우가 많다. 예를 들어, 확인 카테고리에 해당하는 문장인 “약관에 명시된 보험금을 지급하지 않는 사유에 대해 구체적으로 확인하고 싶습니다”라는 ‘확인’이라는 표현이 포함되어 있음에도 불구하고, 문장의 의미상 암 보험 보장 범위 및 지급 사유로 해석될 수 있어 해당 카테고리로 분류되었다. 이에 따라 확인 카테고리에 속한 모든 문장이 다른 카테고리로 분류되었고, 결과적으로 매우 낮은 F1 score가 나타났다.

종합하면, F1 score 분석 결과 표현 패턴이 명확한 카테고리에서는 높은 분류 성능을 보였지만, 의미적 경계가 모호하거나 대화 행위 중심의 카테고리에서는 상대적으로 낮은 성능이 관찰되었다. 이는 LLM 기반 분류기의 한계라기보다는 카테고리 정의 및 태스크 난이도에 따른 차이로 해석할 수 있다.

4 한계 및 향후 연구 제언

4.1 군집화 데이터셋의 한계

본 연구에서 사용한 보험 관련 군집화 데이터셋은 실제 사용자와 챗봇 간의 대화 로그가 아닌, 암보험 상품 요약서(PDF)를 일정 기준에 따라 나누어 구성한 텍스트 데이터이다. 이 과정에서 문맥이 단절되거나 일부 정보가 소실되었을 가능성이 있으며, 실제 사용자가 궁금해하는 질문 유형과는 다소 차이가 있을 수 있다.

또한 일반 대화 카테고리화를 위해 사용한 의료 챗봇 데이터셋은 영문 데이터셋을 GPT-3.5를 통해 한국어로 변환한 데이터로, 실제 한국어 사용자 발화 방식에 비해 일부 문장이 부자연스러운 표현을 포함하고 있을 가능성이 있다. 이러한 번역 기반 데이터는 실제 사용자 질문의 어휘 선택이나 문장 구조를 완전히 반영하지 못할 수 있다.

4.2 Synthetic Data Generation의 한계

본 연구의 테스트셋은 Gemini-2.5-Pro를 이용하여 생성한 합성 데이터(synthetic data)로 구성되었으며, 별도의 검수 과정 없이 바로 실험에 사용되었다. 전반적으로 ground-truth 라벨이 명백히 잘못되었다고 판단되는 경우는 발견되지 않았으나, 일부 문장은 의미상으로 모호하거나 여러 카테고리로 해석될 수 있는 특성을 보이고 있었다.

예를 들어, ground-truth 라벨이 ‘질문 및 요청’으로 지정된 “보험료 납입이 어려워지면 계약이 바로 해지되나요?”라는 문장은 ‘암 보험 해지 및 환급’ 또는 ‘보험료 납입 면제 및 계약 유지’ 카테고리로도 해석될 수 있다. 실제로 LLM은 해당 문장을 ‘보험료 납입 면제 및 계약 유지’로 분류하였다. 이는 하나의 문장에 여러

Table 5: 각 카테고리별 분류 성능

Category	Precision	Recall	F1-score	N
고객 정보	0.57	0.40	0.47	10
다음 단계 안내	0.60	0.30	0.40	10
마무리 및 감사 인사	1.00	0.90	0.95	10
보험 종류 소개	0.50	0.50	0.50	10
보험료	0.71	1.00	0.83	10
보험료 납입 면제 및 계약 유지	0.55	0.60	0.57	10
암 보험 보장 범위 및 지급 사유	0.38	0.50	0.43	10
암 보험 해지 및 환급	0.89	0.80	0.84	10
암 보험금 청구 및 지급 절차	0.45	0.50	0.48	10
인사 및 대화 시작	1.00	0.40	0.57	10
질문 및 요청	0.10	0.10	0.10	10
추가 상담 및 조언	1.00	0.20	0.33	10
확인	0.00	0.00	0.00	10

의미가 내포될 수 있는 자연어의 특성이 합성 데이터 기반 평가에서 성능 해석을 어렵게 만들 수 있음을 보여준다.

4.3 데이터 품질 및 실제 환경과의 차이에 따른 한계

실제 챗봇 환경에서는 사용자가 맞춤법 오류나 오타를 포함한 입력을 제공하는 경우가 빈번하지만, 본 연구에서 사용한 데이터셋은 이러한 노이즈를 충분히 반영하지 못하였다. 이에 따라 실제 환경에서 적용할 때 유형 분류기의 견고성(robustness)이 저하될 수도 있다.

4.4 향후 연구

향후 연구에서는 실제 고객과 상담사 간의 기록, 고객 게시판의 Q&A, 실제 챗봇 문의 로그 등 실제 데이터를 수집하고 정제하여 데이터셋을 구축하고, 이를 바탕으로 군집화 및 유형 분류를 수행하는 방향을 제안한다. 이를 통해 사용자가 실제로 궁금해하는 질문 유형을 더 정확히 반영한 카테고리를 정의할 수 있다.

또한 하나의 문장이 여러 카테고리로 해석될 수 있다는 점을 고려하여, 다수의 검수자가 참여하는 라벨 검수 과정을 도입하고, 단일 라벨 분류(single label classification) 대신 다중 라벨 분류(multi label classification) 방식으로 확장하는 연구 방향을 제안한다.

5 결론

본 연구에서는 비지도 학습 기법인 K-means clustering을 활용하여 보험 및 일반 대화 문장을 군집화하고, 이를 기반으로 유형 분류를 위한 카테고리를 정의하였다. 이후 LLM을 이용해 합성 데이터(synthetic data)를 생성하고, zero-shot prompting 방식의 LLM 기반 유형 분류기를 구성하여 분류 성능을 평가하였다.

본 연구의 주요 의의는 다음과 같다. 첫째, 보험 챗봇 관련 데이터셋이 부재한 상황에서 보험 상품 요약서와 의료 챗봇 데이터를 활용하여 군집화를 통해 의미 있는 카테고리를 추출하였다. 둘째, 명확한 테스트

셋이 존재하지 않는 상황에서 LLM을 활용하여 평가용 데이터셋을 생성하였다. 셋째, zero-shot prompting 방식을 통해 사전 학습이나 추가 미세조정 없이도 LLM 기반 유형 분류기를 구축할 수 있는 파이프라인을 제시하였다.

또한 본 연구는 자연어 문장이 단일 의미만을 포함하지 않는 경우가 많다는 점을, 실험을 통해 확인하였다. 보험 도메인에서 생성된 문장들은 비교적 명확한 의미를 나타냈지만, 의료 챗봇 데이터를 기반으로 생성된 일반 대화 문장들은 의미상으로 모호하거나 여러 카테고리로 해석될 수 있는 경우가 많았다. 이는 향후 자연어 처리 기반 분류 시스템에서 다의적 문장에 대한 분류 전략을 더 정교하게 설계할 필요성을 시사한다는 점에서 의미가 있다.

References

- HanwhaLife. 2025. [한화생명 e암보험\(비갱신형\) 무배당 상품요약서](#).
 Squarelike. 2023. [ko-medical-chat: Korean medical conversation dataset](#).

A Prompt Templates

A.1 Synthetic Data Generation Prompt

A.1.1 Few Shot Prompt

암보험에 가입하려는 고객을 상담하는 챗봇을 생각해보자. 고객이 챗봇에 물어볼 수 있는 질문들을 유형을 분류(Classify)하려고해.

따라서, 고객이 물어볼만한 내용을 라벨에 맞게 지정해준 생성 개수만큼 생성해줘.

[라벨]

{lab}

[생성 개수]

{n_per_label}개

[규칙]

- 한국어로 생성
- 1~3문장 길이
- 유사한 문장 반복 금지
- 실제 암보험 상담/약관/FAQ를 통해 질문할 수 있는 내용으로 생성
- 각 항목은 '한 줄'로 출력 (줄바꿈으로 구분)
- 번호/불릿/따옴표 없이 출력

A.1.2 Zero Shot Prompt

암보험에 가입하려는 고객을 상담하는 챗봇을 생각해보자. 고객이 챗봇에 물어볼 수 있는 질문들을 유형을 분류(Classify)하려고해. 따라서, 고객이 물어볼만한 내용을 아래 Sample을 이용해서 라벨에 맞게 지정해준 생성 개수만큼 생성해줘.

[라벨]

{lab}

[생성 개수]

{n_per_label}개

[Sample]

{samples}

[규칙]

- 한국어로 생성
- 1~3문장 길이
- 유사한 문장 반복 금지
- 실제 암보험 상담/약관/FAQ를 통해 질문할 수 있는 내용으로 생성
- 각 항목은 '한 줄'로 출력 (줄바꿈으로 구분)
- 번호/불릿/따옴표 없이 출력

A.2 Classification Prompt

너는 암보험 상담 챗봇의 유형분류기야. 아래에 주어진 고객의 질문을 읽고, 반드시 아래 Label 중 하나만 선택해서 출력해. 설명, 이유, 추가 문장은 절대 쓰지 말고 Label 이름만 그대로 출력해. 출력에는 한국어 Label만 포함해야하고, 영어, 괄호, 설명을 쓰지마.

[Label 목록]

- 암 보험금 청구 및 지급 절차
- 보험료 납입 면제 및 계약 유지
- 암 보험 해지 및 환급
- 암 보험 보장 범위 및 지급 사유

- 질문 및 요청
- 다음 단계 안내
- 마무리 및 감사 인사
- 인사 및 대화 시작
- 확인
- 추가 상담 및 조언
- 보험 종류 소개
- 고객 정보
- 보험료

[고객 질문]

{row}

[출력 형식]

Label

B 군집 개수에 따른 실루엣 계수 분석

B.1 암보험 관련 데이터에 대한 실루엣 계수 분석




Figure 2: k 값에 따른 실루엣 계수

B.2 일반 대화 관련 데이터에 대한 실루엣 계수 분석




Figure 3: k 값에 따른 실루엣 계수